

Documentação Executiva: Projeto Gendalf

Gestor de Normas e Dados Automatizado

1. Resumo Executivo

O Projeto Gendalf surge como uma solução estratégica para otimizar a governança de dados no DETRAN. Trata-se de um assistente de Inteligência Artificial baseado em arquitetura RAG (*Retrieval-Augmented Generation*), desenvolvido especificamente para indexar, consultar e validar as normas contidas nos manuais internos de padronização de bancos de dados da instituição.

2. Justificativa e Problema Resolvido

- **Desafio:** A verificação manual de conformidade com os manuais de padronização consumia tempo excessivo da equipe técnica e apresentava margem para inconsistências.
- **Solução:** Centralização do conhecimento técnico em um agente digital capaz de responder *queries* complexas instantaneamente, garantindo que novos esquemas e scripts estejam rigorosamente alinhados com as diretrizes do órgão.

3. Arquitetura e Segurança da Informação

Um dos pilares fundamentais do Gendalf é a soberania dos dados.

- **Infraestrutura Local:** O sistema utiliza modelos de linguagem locais (LLM via Ollama), operando inteiramente dentro do ambiente de rede do DETRAN.
- **Privacidade:** Nenhuma informação, esquema de tabela ou dado de consulta é enviado para APIs externas, eliminando riscos de vazamento de dados institucionais e garantindo conformidade com as políticas de segurança pública.

4. Componentes Técnicos (Visão Computacional e Lógica)

Para manter o alinhamento com os padrões de desenvolvimento adotados internamente, o ecossistema foi estruturado utilizando convenções rígidas de nomenclatura (Notação Húngara) para seus componentes de ingestão e interface, garantindo legibilidade e manutenção de longo prazo:

- **Mecanismo de Ingestão:** Processamento de PDFs e manuais de padronização, segmentados em blocos lógicos (*chunks*).
- **Banco de Vetores:** Armazenamento das representações matemáticas do texto para busca semântica precisa.

- **Orquestrador RAG:** Recuperação do contexto exato do manual antes de submeter a pergunta ao modelo de linguagem, mitigando alucinações.

5. Benefícios e Retorno sobre o Investimento (ROI)

- **Redução de Tempo:** Respostas imediatas para dúvidas sobre padrões de nomenclatura, tipos de dados permitidos e restrições de tabelas.
- **Mitigação de Erros:** Diminuição drástica de retrabalho no *deploy* de novos scripts de banco de dados.
- **Facilidade no Onboarding:** Integração mais rápida de novos colaboradores e estagiários à cultura de dados do DETRAN.

6. Evolução Arquitetural e Escolhas Tecnológicas

A arquitetura do Projeto Gendalf foi refinada através de ciclos iterativos, com o objetivo de encontrar a melhor relação custo-benefício entre a precisão técnica das respostas e a viabilidade de execução no hardware local da instituição, garantindo segurança e agilidade.

6.1. Evolução do Modelo de Linguagem (LLM): A Família DeepSeek-R1

O núcleo de geração de respostas do sistema passou por estágios de validação técnica, utilizando diferentes parametrizações do modelo DeepSeek-R1. A versão definitiva escolhida foi o **DeepSeek-R1:8b**, que apresentou o balanço ideal: manteve uma precisão analítica de alto nível com um consumo de recursos substancialmente menor que a versão de 14b, entregando respostas rigorosas sem gargalos de performance.

6.1.1. Análise Empírica de Performance e Acurácia (Benchmark) Para cancelar as escolhas arquiteturais, foi desenvolvido um script automatizado de validação de código SQL, submetendo os modelos a um cenário real de auditoria de banco de dados do DETRAN, os resultados dos testes com os modelos estão no anexo A deste relatório.

6.2. Evolução do Modelo de Embedding (Vetorização)

O modelo de *embedding* é o responsável por transformar os textos dos manuais do DETRAN em coordenadas matemáticas. A escolha definitiva foi o **BGE-M3 (BAAI General Embedding)**, um modelo de estado da arte com suporte robusto ao português, garantindo que o sistema localize a regra exata no manual e elimine ruídos na recuperação de contexto.

6.2.1. Benchmark de Vetorização (Embeddings)

```
RELATÓRIO DE BENCHMARK EMBEDDINGS
Data: 2026-05-18 11:12:50
=====

Textos vetorizados: 10 trechos longos.

Modelo Padrão: bge-m3:latest
Tempo: 5.90 segundos (100%)
Dimensões geradas: 1024
-----

Modelo Teste: nomic-embed-text
Tempo: 1.40 segundos (23.77% do tempo padrão)
Dimensões geradas: 768
-----
```

Apesar do nomic-embed-text levar cerca de 70% a menos de tempo para concluir a vetorização dos textos, o ganho de acurácia com o BGE-M3 é significativamente maior no tocante à fidelidade linguística, algo crucial para a assertividade de um sistema como o Gendalf

7. Arquitetura de Hardware e Escalabilidade (Cluster On-Premise)

A viabilidade técnica baseia-se na execução de modelos pesados sem dependência de Cloud externa.

- **Contingência e Balanceamento:** A comunicação via *Swarm* permite que o sistema escale horizontalmente, equalizando o processamento em caso de picos de consultas simultâneas.
- **Soberania e Blindagem de Dados:** O isolamento absoluto na *intranet* garante o *compliance* com as normas de segurança da informação.

8. Mudança de Paradigma: A Administração de Dados como Instância Revisora e de Inovação

O impacto mais expressivo do Projeto Gendalf é a otimização da governança humana da equipe de Administração de Dados (AD) do DETRAN.

- **Evolução do Papel Técnico:** Com o RAG atuando como filtro primário automatizado para anomalias estruturais básicas (Notação Húngara, sintaxe), a equipe de AD consolida sua expansão de escopo — englobando Arquitetura de Dados, BI e IA — assumindo definitivamente o papel de **instância revisora de alto nível**. O tempo antes gasto em microgerenciamento de padronização agora é direcionado para *tuning* de consultas complexas e projetos estratégicos.
- **Ganhos Mensuráveis:** Redução imediata no gargalo de validação (*Lead Time*), aumento da capacidade de absorver projetos simultâneos sem inflar o quadro, e acultramento orgânico dos desenvolvedores às normativas do DETRAN.

9. Conclusão Executiva

O Projeto Gendalf materializa a modernização da governança de dados na instituição. Ao arquitetar um ambiente local de alta disponibilidade e combinar a precisão de recuperação vetorial (BGE-M3) com o raciocínio otimizado do modelo DeepSeek-R1:8b, o sistema assegura controle total e sigilo irrestrito dos dados em trânsito. O resultado final é uma infraestrutura que previne falhas sistêmicas em banco de dados antes que elas cheguem à produção, consolidando a Administração de Dados como um núcleo estritamente estratégico, multidisciplinar e pioneiro na adoção de Inteligência Artificial no DETRAN.

Anexo A Resultados do tempo de resposta dos modelos(DeepSeek-r1:8b; 1.5b e 14b)

DeepSeek-r1:8b

```
RELATÓRIO DE BENCHMARK LLM
Data: 2026-05-18 11:12:43
=====

Pergunta: a function foi escrita de forma correta?

Modelo Padrão: deepseek-r1:8b
Tempo: 214.33 segundos (100%)
Resposta:
A função não está escrita de forma totalmente correta. Existem alguns problemas:

1. **Nome do parâmetro inconsistente**: O parâmetro de entrada é declarado como 'v_ano', mas na cláusula 'WHERE' está sendo usado 'v_Ano'. Isso fará com que a função não execute corretamente, pois o PostgreSQL é case-sensitive em nomes de objetos.

2. **Tipo de dados do parâmetro**: O parâmetro 'v_ano' é declarado como 'int4' (integer), mas no corpo da função está sendo usado como 'integer' (que é o mesmo, então isso não é um problema).

3. **Retorno SETOF**: O retorno é definido como 'SETOF anochassis_rs', mas não há definição do tipo 'anochassis_rs' no código fornecido. Isso pode causar problemas se o tipo não existir.

**Correção sugerida:**

```sql
CREATE OR REPLACE FUNCTION dbvcen.anochassis(v_ano integer DEFAULT NULL)
RETURNS SETOF anochassis_rs
LANGUAGE plpgsql
AS $function$
BEGIN
 RETURN QUERY SELECT Ano, Codigo
 FROM dbvcen.AnoChassi
 WHERE (v_ano IS NULL OR Ano = v_ano);

 RETURN;
END; $function$
```

**Principais alterações:**

1. **Nome do parâmetro**: Alterado de 'v_Ano' para 'v_ano' para manter consistência.
2. **Sintaxe do parâmetro padrão**: Removido o '::integer' na definição do parâmetro, pois o padrão já é 'integer'.
3. **Retorno SETOF**: Mantido como está, mas é importante garantir que o tipo 'anochassis_rs' exista.

Essas alterações devem resolver os problemas identificados.
```

O modelo escolhido para o Gendalf foi o DeepSeek com 8 bilhões de parâmetros, por atender à necessidade de uma resposta acurada e rápida. No tocante à qualidade da resposta, o 8b não ficou muito atrás do 14b no quesito qualidade e clareza da resposta, e por ser um modelo mais leve, o 8b mostrou-se mais eficiente que o 14b e mais acurado que o 1.5b

DeepSeek-r1:1.5b

```
Modelo Teste: deepseek-r1:1.5b
Tempo: 36.01 segundos (16.80% do tempo padrão)
Resposta:
A função escrita no PL/SQL tem dois problemas principais:

1. **Variable Nome Distinguido do Parâmetro**:
  - O parâmetro da função é `v_ano`.
  - No SQL-clause, o comando está verificando `v_ano`, mas shouldermos usar `v_Ano` para manter a correcção.

2. **Formato Lógico dos Comandos SQL**:
  - As linhas de código são embaixadas.
  - Os comandos deSQL não possuem semicolos e não são fechados.

Para corrigir:

```sql
CREATE OR REPLACE FUNCTION dbvcen.anochassis(v_ano integer DEFAULT NULL::integer)
RETURNS SETOF anochassis_rs
LANGUAGE plpgsql
AS $function$
BEGIN
 -- Verifica se o ano é null ou igual ao valor passado em parâmetro.
 IF v_ano IS NULL OR v_ano = v_Ano
 THEN RETURN QUERY SELECT Ano, Coder FROM dbvcen.AnoChassi;
 END;

 -- Devo executar o Query para obter os dados dos resultados.
 RETURN (SELECT Ano, Coder FROM dbvcen.AnoChassi);
END $function;
```

Agora, para usar a função:

```sql
-- Exemplo de uso da funcao.

-- Seja Ano do arquivo arquivos que você quer incluir:
SELECT Ano from dbvcen.arquivos where Ano in (2014, 2015);
```
```

O DeepSeek-r1:1.5b foi o primeiro modelo usado no projeto, para criar uma noção de que o projeto era viável no início da tarefa, apesar de responder em menos de 1 minuto, o modelo com 1 bilhão e 500 milhões de parâmetros deixa muito a desejar na qualidade da resposta, sendo inviável para um projeto com a magnitude do Gendalf.

DeepSeek-r1:14b

```
Modelo Teste: deepseek-r1:14b
Tempo: 298.53 segundos (139.29% do tempo padrão)
Resposta:
A função 'anochassis' foi escrita corretamente no PostgreSQL, exceto por um ponto que pode causar problemas: a instrução 'RETURN;' após o comando 'return query'. No PostgreSQL, funções que retornam conjuntos de resultados (tipo 'RETSOF') não devem usar 'RETURN;' novamente.

**Passo a passo da resposta:**

1. **Estrutura da função:** A função está corretamente estruturada com 'CREATE OR REPLACE', esquema adequado e parâmetros.

2. **Comando de retorno:** O comando 'return query' é usado adequadamente para selecionar os dados desejados.

3. **Problema:** A instrução adicional 'RETURN;' após o 'return query' pode causar um erro, pois no PostgreSQL, após usar 'return query', não é necessário outro 'RETURN'.

4. **Solução:** Remover a segunda 'RETURN;' para corrigir a função.

Portanto, a função está quase correta, mas precisa remover a instrução 'RETURN;' duplicada.
.....
```

O maior dos modelos testados, o DeepSeek:14b mostrou-se bastante acurado em suas respostas, mas o peso extra (pouco mais de 9 Gigabytes em relação aos 5,3 Gigabytes do 8b) fez com que o o o 14b apresentasse uma alta latência na geração de inferências, especialmente com contextos extensos, no caso em tela, houve um aumento de quase 40% do tempo gasto para geração da resposta, algo que iria se acumulando ao longo do tempo e por fim, poderia derrotar o propósito do Gendalf como ferramenta.